Avaliação do relatório

- **Grupo:** Gabriela Neres, Mariane Melo, Pedro Lopes
- **Capítulos entregues:** 6/6
- **Relatório entregue no prazo:** Sim
- **Nota:** A

Comentário geral

Todos os capítulos foram apresentados, a maioria usando os próprios dados como estudos de caso - ótimo e parabéns! Alguns pontos a serem considerados futuramente:

- Destacar melhor as hipóteses e objetivos em cada capítulo.
- Discutir em mais detalhe os resultados (e figuras) apresentados; na maioria das vezes foi destacado apenas a questão de significância estatística, sem se ater ao sinal dos parâmetros e em que escala eles estão sendo interpretados.
- Descrever melhor a metodologia de coleta dos dados, especialmente no capítulo sobre dados discretos. Lembrem-se: se o esforço amostral não foi constante, é necessário utilizar o offset. Vocês não discutiram esse aspecto.

Apesar dessas ressalvas pontuais, o relatóro está satisfatório diante dos propósitos da disciplina.

Comentários específicos

Cap. 1: Dados binários

- Seção 1:
  - A introdução está muito clara e objetiva, destacando claramente qual o objetivo do capítulo. Parabéns!
- Seção 4:
  - Todas as colunas foram transformadas como numéricas. No entanto, seria mais adequado transformar as duas primeiras colunas (`site` e `subsite`) como fator, já que representam os locais de amostragem/subamostragem.
- Seção 5.3:
  - Faltou discutir as figuras apresentadas.

- Seção 6:
  - Muito bom terem exposto de forma tão clara os modelos que testaram.
- Seção 6.2:
  - A interpretação dos resultados dos LRTs está equivocada, e também faltou deixar mais explícito qual o modelo escolhido após a análise dos AICs e LRTs.
    - Não tem como se atribuir um senso de 'importância' das variáveis pelos LRTs efetuados. Para tal, seria necessário realizar os LRTs comparando o modelo nulo (mod0) com cada modelo de variável única (mod1, mod2).
    - O primeiro LRT avalia se a inclusão da variável *árvores secundárias* (psec_ssite) no modelo que já tem *árvores primárias* (mod1) melhora significativamente o ajuste (mod3).
      - Neste caso, como o p-valor foi maior que 0.05 (nível de significância de 5%), isso implica que a inclusão de árvores secundárias não resultou em redução significativa da deviance; logo, variável não reduz a variabilidade que é observada na probabilidade de presença de coalas.
    - O segundo LRT avalia se a inclusão da variável *árvores primárias* (pprim_ssite) no modelo que já tem *árvores secundárias* (mod2) melhora significativamente o ajuste (mod3).
      - Como o p-valor foi menor que 0.05, isso implica que adicionar árvores primárias melhora significativamente o modelo com árvores secundárias; portanto, reduz a variabilidade na probabilidade de presença de coalas.
    - Conclusão geral: A análise do AIC sugere que o modelo usando apenas arvores primárias (mod1) como covariável é o mais adequado. Os LRTs complementam essa conclusão: o teste mod2 vs mod3 indica que a variável das árvores primárias é importante, mesmo na presença das secundárias. Por outro lado, o teste mod1 vs mod3 sugere que a variável das árvores secundárias não reduz significativamente a deviance do modelo que já considera as árvores primárias. Dessa forma, pode-se concluir que o modelo mod1 é o mais parcimonioso para explicar a presença dos coalas.
- Seção 7:
  - Apesar dos resultados das análises residuais estarem expostos, faltou vocês discutirem esses resultados: o que estão observando e como interpretar?
    - Por exemplo: o teste de autocorrelação mostrou que os resíduos estão correlacionados entre si. Como proceder em casos assim?
- Seção 8:
  - Interpretação equivocada dos resultados - confusão com os termos *probabilidade* e *chance*.
    - Dado a função de ligação (i.e., logit), os resultados são interpretados sob a perspectiva de *razão de chances*. Nesse contexto, pode-se interpretar os resultados como: cada incremento de 1% em árvores primárias aumenta em cerca de 3,5% as chances de ocorrência de coala. Isso vale tanto para os resultados expressos na escala da função de ligação (logit) quanto na escala natural (inverso da logit -> exp).
    - Para interpretar os resultados sob a ótica de *probabilidades*, é preciso converter os parâmetros conforme a relação:

$$p = \frac{1}{1 + exp(-\eta)}$$

onde η é o preditor linear.

- O uso do termo 'a presença de coalas é **muito significativa**' deve ser evitado. Conforme comentado em sala de aula, o número de asteriscos e o valor do p-valor não medem o grau de significância biológica e muito menos a força da relação; apenas diz se o coeficiente associado à variável é estatisticamente diferente de zero — ou seja, se rejeitamos a hipótese nula de ausência de efeito. Em tese, não comprovamos efetivamente a nossa hipótese (presença de efeito da variável); apenas rejeitamos ou deixamos de rejeitar a hipótese nula. Quando p-valor < 0.05, rejeitamos a hipótese nula e podemos afirmar que há uma relação entre a covariável a variável resposta. Repare, contudo, que não temos como atribuir o sentido de 'força' de relação (a relação é muito forte, ou muito fraca, ...).

Cap. 2: Dados discretos

- Seção 1:
  - Em se tratando de dados de contagem, seria interessante saber mais detalhes sobre a metodologia de coleta para saber se o esforço amostral foi mantido constante ao longo das amostragens. Caso tenha variado, é importante fazer uso do `offset` para contabilizar a diferença de esforço na estimação da riqueza. Considerem isso em modelos futuros!
- Seção 3:
  - Considerem transformar as variáveis `cd_site`, `month` e `year` como fator, caso forem utilizá-las em modelos futuros.
- Seção 4:
  - Reparem que para a variável `ROADS_R` há uma única amostra que se destaca de todas as demais. Para análises futuras, considerem verificar o que está ocorrendo com essa variável, caso seja utilizada.
- Seção 5:
  - Quais os problemas de ajustes verificados para o modelo *m.poiss*? As figuras foram apresentadas, porém não comentadas.
    - O modelo inclui a variável 'mês'; esta variável está codificada como 'numérica', mas seria mais interessante transformá-la para 'fator', conforme sugerido previamente.
    - Vocês comentam que detectaram autocorrelação espacial para o modelo *m.poiss2*, porém não exploraram isso explicitamente na figura que expuseram. Como vocês detectam autocorrelação nela?
  - No modelo *m.poiss3* faltou expor o por quê de terem usado a interação 'x * y' e não a simples adição desses termos. Testaram um modelo usando apenas os termos aditivos?
  - Legal vocês terem aplicado a função `stepAIC()` para selecionar modelos! Só faltou vocês serem mais claros, no texto, sobre os dois modelos que vocês escolheram após a aplicação dessa função (p.simpl1 & p.simpl2).
    - Percebi que esses modelos incluem tanto long/lat como efeitos aditivos, quanto efeitos multiplicativos. Seria interessante vocês justificarem o por quê dessa distinção e o que isso significa na prática.
  - Os resultados do modelo `p.simpl1` são apresentados, porém não discutidos. Faltou essa parte... faltou também vocês incluírem, na análise residual, a verificação da sobredispersão.
  - Como vocês interpretam os parâmetros? Em que escala eles estão?
- Seção 6:
  - Vocês poderiam terem enfatizado mais o por quê de testarem uma distribuição Binomial Negativa. Lembrem-se: a sobredispersão é um problema que acompanha dados de contagem, e portanto é importante verificar esse aspecto sistematicamente!

    - A distribuição Poisson assume que a $\mu = \sigma$ (média igual a variância). Ela assume que a dispersão seja constante, o que não ocorre na maioria dos casos. A distribuição Binomial Negativa é uma alternativa interessante, porque a variância da distribuição é descrita em função de um parâmetro de dispersão (ϕ). Logo, é uma alternativa para dados de contagens com sobredispersão.
  - Faltou justificarem os diferentes tipos de modelos testados (apesar de apresentarem os resultados).
  - Teria sido interessante comparar os AICs do melhor modelo Poisson com o melhor modelo Binomial Negativo.
  - Faltou consistência na avaliação dos pressupostos; por exemplo, vocês não avaliaram autocorrelação espacial nos modelos BN.
  - Como vocês interpretam os parâmetros? Em que escala eles estão?
  - Embora o modelo binomial negativo tenha melhorado significativamente o ajuste dos dados, a análise residual ainda mostra várias violações. Isso é indicativo que o modelo ainda não está adequado e, portanto, necessita de mais modificações. Vocês lembram a quais alternativas podemos recorrer?

- Seção 7:
  - Faltou maior clareza do por quê terem utilizado 12%, 10% e 100 como referência para predizer a riqueza em função de agricultura intensiva, área urbana e metros de estrada construída.

Cap. 3: Dados contínuos

- Seção 1:
  - Introdução muito bem descrita. É sempre importante que o leitor seja guiado minimamente para se situar dentro do problema proposto.

- Seção 5:
  - Me parece que a variável `rang_corr` poderia ser codificada como fator. Seria interessante justificar o por quê de terem usado a variável como numérica.
  - Embora comentem que a ordem do rio não parece estar relacionada com o LCBD, eu consigo visualizar um padrão côncavo na relação dessas duas variáveis, com picos de LCBD ocorrendo entre a ordem de rio 3.5 e 4.

- Seção 8:
  - Faltou uma interpretação mais detalhada dos resultados. Os efeitos foram negativos, positivos? Em que escala os parâmetros estão expressos? Como interpretar os resultados na presença de uma variável categórica?...

- Seção 9:
  - Esta seção deveria ser explorada na seção 7, antes de interpretar os resultados do modelo.
  - Como os dados apresentam um componente temporal, deveria ser avaliado também a autocorrelação temporal (via acf plot, por exemplo).

Cap. 4: Dados categóricos

- Seção 1:

  - Se formos seguir o modelo apresentado na seção 5, o que está sendo avaliado é a relação entre condição de saúde e estágio de desenvolvimento
    * e não de modo contrário, como exposto no texto.

- Seção 4:
  - Poderiam descrever o que estão observando na figura - por exemplo, a maioria dos adultos estão acima do peso, etc.

- Seção 6:
  - Faltou expor a tabela (summary) do modelo e detalhar mais como o resultado pode ser interpretado (estão usando uma *covariável* categórica, cujo primeiro nível é absorvido pelo intercepto).

Cap. 5: Distribuições complementares

- Seção 4:
  - Considerem transformar a variável `year` para fator em avaliações futuras.

- Seção 5:
  - Não está claro por que estão analisando os dados especificamente para a comunidade 'U012'. Sejam mais claros.
  - Faltou justificar o por quê de terem usado um *threshold* de 5 quando aplicam a função `vifstep()`.
  - Vocês comentam "*Não parece haver correlação entre as variáveis*"
    * Há correlação, porém como todas estão abaixo de 0.7 (70%), pode-se interpretar que não há uma multicolinearidade expressiva
      · Uma exceção parece ser a variável `PCT_EXTENSIVE_AGRICULTURE`, a qual apresentou uma correlação próxima a 0.7.
  - Vocês comentam: "*nenhuma das variáveis parecem ter muita relação com o LCBD.*".
    * Discordo da afirmação, uma vez que se consegue distinguir alguns padrões bem claros. Por exemplo, o gráfico da relação LCBD e tipo de rio mostra uma clara tendência de maiores beta diversidades em rios intermitentes. Pode-se detectar também uma relação diretamente proporcional com a ordem dos rios e agricultura intensiva - nesses casos, LCBD parece aumentar com o aumento da ordem dos rios e com áreas com maior intensidade de agricultura intensiva.
      · Vocês poderiam ter calculado a correlação entre a variável resposta e essas covariáveis para terem uma ideia da magnitude dessas relações.

- Seção 6:
  - Faltou justificar por quê avaliaram essas variáveis em modelos separados. Qual/quais a(s) hipótese(s) em jogo?

- Seção 7:
  - A diferença de AICs entre ambos os modelos é muito marginal e pelo AIC não teria como concluir qual modelo é de fato melhor. Vocês fizeram o certo em avaliar os ajustes gráficos de ambos os modelos.
  - Vocês comentam: "Nenhum modelo parece muito bom."
    * Cuidado com essa afirmação. Primeiro, não se tem como fazer este tipo de afirmação avaliando apenas um gráfico de valores observados vs. valores preditos, como vocês fizeram. Segundo, o modelo `model_beta` mostra que os valores preditos pelo modelo estão muito próximos dos valores observados (observem o *range* dos valores nos eixos y e x). Além disso, a relação é claramente positiva. Por esse gráfico, eu interpretaria que, à priori, o modelo apresenta um bom ajuste.

  - Faltou discutirem em mais detalhes os resultados observados. Em que escala estão os parâmetros quando se utiliza uma distribuição Beta? Poderiam ter relacionado com as figuras apresentadas na seção 8.

- Seção 9
  - Esta seção deveria ser explorada na seção 7
  - Como os dados apresentam um componente temporal, deveria ser avaliado também a autocorrelação temporal (via acf plot, por exemplo).

Cap. 6: GAM

- Seção 1:
  - Repito meu comentário feito no cap. 2, i.e., como se trata de um dado de contagem, é fundamental que o trabalho forneça maior detalhamento sobre a metodologia de coleta para saber se o esforço amostral foi constante ou não.
    * Pelo estudo apresentado, me parece que área (ou volume) pode/deve ser considerado como offset no modelo.

- Seção 4:
  - O que vocês observaram no gráfico? Faltou discutir...
  - Observando os gráficos, há uma amostragem cujo valor de riqueza foi bem alto quando a área e o volume de amostragem eram as maiores. O que ocorreu alí? Esse padrão pode ser que seja necessário transformar a riqueza em log para dar uma achatada nesses valores tão extremos.

- Seção 5:
  - Não ficou claro do por quê as vezes testarem a área e as vezes o volume. Qual a hipótese de vocês?
  - Os resultados apresentado carecem de maior discussão; é importante mencionarem o uso da distribuição poisson e binomial negativa, já que ambas são testadas. As análises residuais demonstram claramente que há um valor muito influente nos resíduos - provavelmente aquele valor que destaquei na seção 4. O que fazer com esse valor? Vocês não discutem isso..
  - Poderia ter sido interessante testar um termo quadrático de volume (ou área) para ver como se dá o ajuste do modelo em comparação com o modelo GAM.