Avaliação do relatório

- **Grupo:** Maria Carolina Pacheco
- **Capítulos entregues:** 6/6
- **Relatório entregue no prazo:** Não
- **Nota:** B

Comentário geral

O relatório apresentado demonstra um bom domínio dos principais conceitos trabalhados ao longo da disciplina, bem como um esforço consistente em aplicar as técnicas de GLM e GAM aos próprios dados. As análises estão, no geral, claras e bem conduzidas, e suas interpretações fazem bom uso do raciocínio estatístico desenvolvido ao longo do curso. Para aprimorar ainda mais, sugiro detalhar um pouco mais os conjuntos de dados e explorar melhor a interpretação dos resultados diante das funções de ligação que acompanham cada distribuição de probabilidade.

Comentários específicos

Cap. 1: Dados binários

- Seção 1:
  - Bacana que adaptou seus dados para rodar um exemplo de modelo logístico!
  - Uma curiosidade: esses dados foram frutos de experimento em laboratório?
  - Teria sido interessante você incluir um pouco mais de detalhes sobre o seu *set-up* experimental. Mais em baixo, por exemplo, você comenta sobre o fato de que o experimento possui medidas repetidas. Isso seria importante mencionar aqui no início, aonde explica o seu banco de dados.
- Seção 3:
  - Bem interessante o padrão observado na sua primeira figura!
  - Preciosismo: considere usar a função `facet_grid()` ao invés de `facet_wrap()` para gerar a sua 2a figura - vai melhorar um pouco a interpretação dela.
  - Você comenta: "*Os corais aquecidos parecem...*"
    - Considere mudar para algo na linha de: "*Os corais submetidos à temperaturas mais quentes...*".
  - Você fala: "*Apesar disso, ainda parece ter ocorrido um pequeno efeito da manipulação nos controles.*"
    - Também fiz a mesma leitura. Mas o que pode ter acontecido?

  - Para a questão de medidas repetidas, considere recorrer a um GLMM aonde pode incluir o ID do coral como efeito aleatório
    * Isso, claro, em trabalhos futuros e não a título desse relatório, que é mais simples.
  - Quando você filtra os dados para avaliar apenas o dia 32 do experimento, quantas amostragens (linhas) lhe sobraram para rodar os modelo? Mera curiosidade...
  - Suas análise exploratória está muito bem esturutrada. Parabéns.

- Seção 4:
  - Seria pertinente você mencionar, brevemente, a metodologia que você adotou para testar e selecionar modelos - inclusive, justificar o modelo em que avalia a interação entre tratamento e hábitat.
    * No seu caso, vejo que você adotou o método de 'forward step-wise', em que vai aumentando gradualmente o nível de complexidade do modelo.
  - Hmh, você comenta que o modelo 3 foi o que resultou no menor AIC.
    * Repare, contudo, que a diferença de AICs entre os modelos `mod1` à `mod3` é mínima. Aqui caberia um teste de razão de verossimilhança (LRT) para comparar, por exemplo, o modelo mais complexo (`mod3`) com o modelo mais simples (`mod1`).
      · Desconfio que não haverá diferenças significativas. Se for o caso, pelo princípiode parsimôniam se escolheria o modelo mais simples.

- Seção 5:
  - Caberia discutir em poucas linhas o que exatamente você observou na sua análise residual.

- Seção 6:
  - **Cuidado!** Você comenta que "*O modelo mostrou que houve efeito significativo somente dos fatores principais*".
    * Tecnicamente, os efeitos não foram estatisticamente significativos porque os p-valores são todos > 0.05. Você precisa reajustar a interpretação dos seus resultados.
  - Observações pontuais:
    * Falotu você explorar os resultados sob o aspecto da escala em que os coeficientes foram estimados (logit), e como eles são interpretados. Isso é particularmente imporante no contexto de modelo binomial/multionomial, porque a interpretação difere bastante dos demais GLMs.
  - Veja o valor de `Std. Error` para o parâmetro de `tratC:habitatT` - está enorme! Há algo acontecendo alí que precisaria ser investigado, caso prosseguisse com esse modelo.

Cap. 2: Dados discretos

- Seção 1:
  - **Opa!** Carececeu desenvolver essa seção. Por exemplo, você não comenta nada sobre o banco dados, nem dá indícios do que será sua variável resposta. Repare como a próxima seção você desenvolve um pouco mais... é importante sempre guiar o leitor.
    * Seria interessante você também apresentar o que são dados discretos e quais as distribuições de probabilidade mais adequadas para esse tipo de dado.

- Seção 2:
  - **Cuidado!** Você comenta: "*... com frequência de zeros bem alta.*"

    * As barras representam *calsses* em que os valores estão agrupados, e não valores de riqueza unitários como você está interpretando. A primeira barra mostra a classe de riqueza que vai de 0 à 5 espécies, i.e., contabiliza-se o número de amostras cujas riquezas oscilaram de 0 à 5 espécies.
        · Para saber se seu dado teve uma alta frequência de zeros, você precisaria computar:

```
table(dados$Richness == 0)
```

```
##
## FALSE  TRUE
##    42     3
```

- Você comenta: "*Somente as praias 1 e 2 parecem diferentes das outras.*"
  - Concordo em parte! Repare que, no geral, a riqueza varia entre praias, sendo que as praias 1 & 2 apresentaram as maiores riquezas de espécies.
- Seção 3:
  - Parabéns pela clareza da exposição das suas hipóteses.
    * Preciosismo: o título da sua seção fala em 'predições', mas você só destacou as hipóteses.
- Seção 4:
  - Conforme destacado no capítulo anterior, você poderia ter utilizado um LRT (teste de razão de verossimilhança) para testar se o modelo mais complexo difere estatísticamente do modelo mais simples. Provavelmente não irá diferir, mas você teria um respaldo estatístico...
  - Lembrando que a principal diferença entre um modelo Poisson e BN, é que a distribuição Poisson assume que $\mu = \sigma$ (média igual a variância). Já a distribuição BN, a variância é descrita em função do parâmetro de dispersão k, conforme: $\mu + \frac{\mu^2}{k}$.
  - Interessante ver que o modelo BN não reduziu expressivamente o AIC; o valor é muito próximo ao modelo Poisson.
    * Isso é um indício de que o dado não é sobredisperso, e portanto não faz sentido recorrer a uma distribuição que tem um parâmetro a mais para estimar (k).
  - Você comenta: "*Aqui achei que piorou o gráfico da variância residual. A linha dos dados observados está mais longe da predita do que no modelo 1*"
    * Acho que aqui você se refere ao gráfico de 'Misspecified dispersion and zero-infaltion', não? Confira isso!
  - A sua interpretação dos parâmetros está corretíssima. Contudo, assim como no último capítulo, faltou você destacar em que escala esses parâmetros estão sendo estimados (log), bem como detalhar mais o resultado em relação a sua variável `Exposure`, codificada como fator. Lembre-se quando você insere variáveis preditoras que são categóricas, o primeiro nível do fator será *sempre* absorvido pelo intercepto (baseline). Logo, todos os coeficientes são relativos ao intercepto.

Cap. 3: Dados contínuos

- Seção 1:
  - Faço o mesmo comentário feito no último capítulo: Seria interessante apresentar o que são dados contínuos e quais as distribuições de probabilidade mais adequadas para esse tipo de dado. Daí fazer um paralelo com seus dados (taxa de fagocitose)

- Seção 2:
  - Interessante a sua análise exploratória preliminar!
- Seção 3:
  - Penso que faria mais sentido apresentar suas duas primeiras frases desta seção na sua Introdução. Havia, inicialmnete, feito o questionamento na sua Introdução sobre a relação de fagocitose e ondas de calor. Vim achar minha resposta aqui!
- Seção 4.1:
  - De fato, a homogeneidade das variáncias está pecando um pouco, mas tá longe de ser uma violação expressiva.
    - Quando você coletou as suas amostras, elas foram coletadas todas no mesmo dia?
      - Caso tenha sido coletado em dias diferentes, você poderia usar o dia como uma variável aleatória no contexto de um GLMM. Acredito que isso resolva o problema da sua variância.
  - Você usa o termo "*taxa fotossintética*"
    - Isso é equivalente de taxa de fagocitose?
  - Qual a escala que os coeficientes do seu modelo estão sendo expressos?
  - Sua interpretação dos resultados estão todas corretas, mas daria para polir um pouco mais.
    - Por exemplo, você não destaca a questão da significância estatística dos parâmetros.
    - Além disso, você fala: "*Os corais saudáveis apresentam maior taxa de fagocitose.*"
      - Em relação a que? E como você chegou a essa conclusão? (Sei que é pelo valor numérico do parâmetro ser maior; mas você precisa indicar isso mais claramente.)

Cap. 4: Dados categóricos

- Seção 2:
  - Sua análise exploratória está clara e objetiva!
    - Fatlou apenas comentar o que você observou na última figura.
- Seção 3.1:
  - As interpretações dos resultados referente à `mod_pin1` estão corretas, mas faltou destacar a questão da significância estatística bem como interpretá-los na escala da função de ligação.
    - Lembre-se que a interpretação é similar a do modelo logístico, i.e., log(razão de verossimilhança). Você está confundindo *probabilidade* vs. *razão de chances*.
  - Reptio meus comentários anteriores para os resultados referente à `mod_pin2`.
  - **Opa!** Faltou você rodar um modelo com a variável `sex`. Você apresenta ela como parte das suas hipóteses e e na sua análise exploratória.

Cap. 5: Distribuições complementares

- Seção 1:
  - Legal a forma que você apresentou os dados na introdução. Veja como esse nível de detalhamento ficou faltando em alguns capítulos anteriores...
- Seção 2:

  - Agora que vi que você usou uma palheta de cor chamada 'coral'... hehe
  - Achei bem interessante você ter explorado um tipo de gráfico diferente para tentar ver as interações.
    * Temos indícios de que há interação quando as linhas se cruzam. Isso parece ocorrer mais intensamente nos 20 primeiros dias; depois há uma separação brusca entre corais do topo e da base, sem interações expressivas dentre e entre esses dois níveis. Saberia do por quê desse padrão? Mera curiosidade...

- Seção 3:
  - **Cuidado!** Vejo que sua variável resposta `yii` tem 9 NAs. Você precisa verificar isso. Caso não consiga recuperar essas informações, é preciso remover essas linhas do seu banco de dados.
  - Que bom que lembrou de adicionar uma pequena constante à sua variável resposta para poder adequar à distribuição Beta.
  - Você precisa rever seu texto que aparece após "*Vou começar mais simples, ...*" - está um tanto quanto confuso.
  - Achei bem legal também que já testou a questão do efeito aleatório, apesar que eu não tenha apresentado isso explícitamente na disciplina.
  - Podemos ser muito criativos com nossos modelos - nada nos impede. Entretanto, é sempre bom ter em mente que precisamos conseguir explicar os resultados. Acho a inclusão de termos de interação muito úteis e por vezes necessário. Mas quanto mais interações incluir, mais complicado fica a interpretação.
    * Como você explicaria a interação entre `trat*dia_exp*habitat`?
  - Você comenta: "*Usando o pacote DHARMA não está parecendo bem ajustado*"
    * Entendo que você quer dizer isso em relação ao painel direito. No entanto, eu não me preocuparia muito com as linhas vermelhas (indicadoras), e sim mais como os pontos estão distribuídos ao fundo. Não parece haver um padrão marcante nos resíduos.
  - Você comenta: "*O grafico da homogeneidade de variancia ainda não ta muito reto e horizontal. Será que eu devia rodar um GAM?*"
    * Talvez caberia incluir o dia do experimento como efeito aleatório também.

- Seção 3.1:
  - Desenvolva um pouco mais a exploração dos seus resultados. Também parece que você engoliu algumas palavras...

- Seção 3.2:
  - Repare na mensagem gerada depois que você usou a função `ggpredict()`
    * Ela está lhe sugerindo algo, dado que você está usando um GLMM como modelo de entrada na função...

Cap. 6: GAM

- Seção 2:
  - O que poderia estar gerando esses 0? Alguma hipótese?
  - O que me chama atenção no seu gráfico de `yii` vs `exp_day` é uma queda mais acentuada da taxa fotossintética até o 10o dia, depois ela se mantém razoavelmente constante, próximo ao valor de 0.5.
    * Bacana ver que você foi testando diversos visuais diferentes para gerar os seus gráficos! Repare no poder de uma figura bem apresentada! Chama muito mais atenção e dá mais 'gosto' de ler e interpretar o gráfico.

        - Seu terceiro gráfico, por exemplo, eu reparei que você escolheu uma palheta de cores que casou muito bem com o contexto do seu experimento (laranja = água mais quente; turquesa = água mais fria). Veja como isso torna a leitura mais intuitiva e fácil.
    - Você comenta: "*Essa espécie parece ter uma diferenciação maior entre topo e base.*"
        - Sim, mas reparei também que há maior diferença entre os corais do topo e base quando sob tratamento (A.B e A.T).

- Seção 3.3
    - Cabe você explorar bem mais a sua seção de resultados do modelo GAM.
        - Por exemplo: como você interpreta o termo `edf` no efeito suavizador?
        - Quanto da sua deviance está sendo explicada?
        - E o gráfico dos efeitos parciais?
    - Olhando novamente para o seu primeiro gráfico, penso que talvez seria interessante você testar a distribuição de probabilidade `Tweedie`
        - Dei essa distribuição na 7a aula