Avaliação do relatório

- **Grupo:** Bianca Guerreiro
- **Capítulos entregues:** 4/6
- **Relatório entregue no prazo:** Não
- **Nota:** B

Comentário geral

Foi muito bom ver que você explorou a maior parte dos capítulos utilizando seus próprios dados, o que demonstra um domínio das ferramentas analíticas apresentadas. Seu nível de programação está muito bom, e a forma como automatizou algumas etapas mostra uma compreensão sólida de lógica computacional - muito legal! Recomendo, contudo, que em trabalhos futuros você inclua uma seção de análise exploratória, etapa essencial para compreender os dados antes da modelagem, e busque manter um padrão mais consistente na apresentação entre os capítulos. Em alguns momentos você descreve claramente as hipóteses e as distribuições adequadas a cada tipo de dado, enquanto em outros esses pontos ficam apenas implícitos. Garantir essa coerência e clareza metodológica tornará suas análises mais sólidas e transparente. Por fim, ressalto que o relatório careceu de dois capítulos: distribuições complementares e GAM.

Comentários específicos

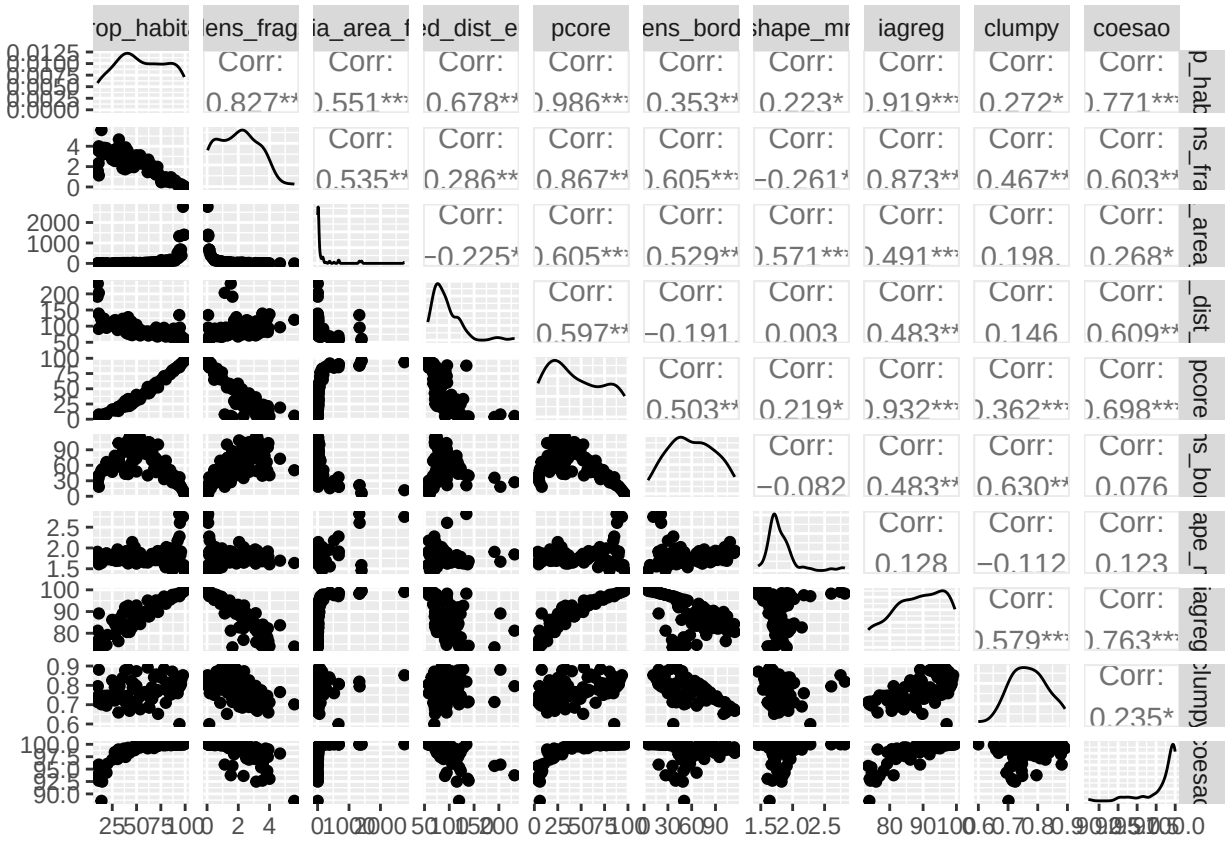
Cap. 1: Dados binários

- Seção 1.1:
  - Legal que está usando seus próprios dados para aplicar o exemplo de um modelo logístico (Binomial). Sua introdução está muito bem estruturada: clara e concisa!
    - Obrigada por apresentar de forma tão clara o significado de cada coluna do seu banco de dados.
  - Curiosidade: os valores que aparecem para a variável `buffer` (e.g., 399, 688, etc.) representam o que exatamente? Sei que é relacionado à escala espacial, mas isso representa área? metros?
  - **Preciosismo:** reparei que sua variável `med_dist_eucl` possui NA's. Lembre-se de que é importante investigar a causa desse valor faltante - tanto para essa coluna, quanto para as demais colunas.
    - Há formas de inserir dados faltantes por uma técnica de "*data imputation*". Em muitos casos, no entanto, acaba-se retirando essa linha do banco de dados (a função `glm` faz isso automaticamente).
- Seção 1.2:

- Sua abordagem em avaliar a multicolinearidade entre suas diferentes variáveis está corretíssima. No entanto, em um segundo momento, considere avaliar a multicolinearidade *entre* as variáveis retiradas para os diferentes buffers (399, 1844, 3000, ...). Isso é essencial, porque certamente haverá alta colinearidade para a mesma variável capturada em buffers diferentes.
    - Dito isto, entendo que você ainda esteja na fase de explorar os dados e que quis simplificar para o relatório.
- **Cuidado!** Você comenta: "*... e uma delas era dados$prop_habitat, essa última foi priorizada para ser mantida...*"
    - Sua lógica em padronizar o dado está correta, mas isso precisaria ser aplicado para todas as demais covariáveis também. Não se padroniza apenas uma única variável; por via de regra e consistência, se padronizar uma variável, padroniza-se todas as demais também.
- Sugestão: como você possui muitas covariáveis, você poderia também aplicar uma análise de componentes principais (PCA) para reduzir a dimensionalidade - principalmente porque você tem os mesmos conjuntos de variáveis medidos em escalas espaciais diferentes. Isso evitaria de você ter que filtrar os dados para cada buffer e avaliar multicolinearidade em cada um deles, como o faz mais abaixo.
- Sugestão 2: para melhor visualizar as correlações cruzadas, você poderia fazer uso da função `ggpairs()` do pacote `GGally`, ou a função `corrplot` do pacote do mesmo nome, conforme indicado abaixo:

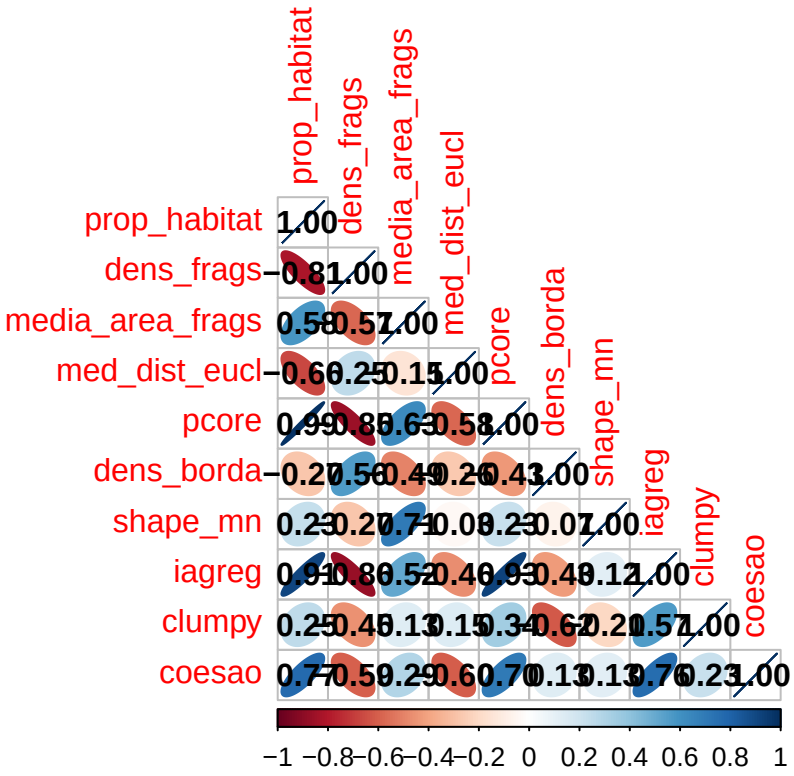
```
library(GGally)

ggpairs(b3000[,5:14])
```



```r
library(corrplot)

corrplot(cor(b3000[,5:14],
         use = "complete.obs"),
         addCoef.col = "black",
         type = "lower",
         method = "ellipse")
```



- Há duas colunas suas com a presença de NAs: `med_dist_eucl` e `clumpy`. Isso precisa ser verificado, tá?
- Seção 1.3:
  - A sua análise exploratória está interessante, mas há formas mais interessantes de explorar os dados. Um histograma, por exemplo, é útil para avaliar a distribuição dos dados da *variável resposta*. Esse gráfico, contudo, nãofornece informação sobre a relação da sua variável resposta com sua covariável.
    - Isto é o que de fato avaliamos em LMs, GLMs, GAMs,. . . .
    - Para isso, você pode/deve usar gráficos de dispersão, linha, boxplots. . .
  - **Dica:** vejo que você repetiu muito código manualmente para gerar as diferentes figuras. Sempre que você se encontrar em uma situação assim (ter que repetir o mesmo código com diferentes inputs), saiba que há formas de automatizar esses passos.
    - Em programação, isso faz parte do que chamamos de otimização! Além de deixar o código mais curto, evita o acúmulo de erros dado à nossa desatenção.

    * Sugiro você começar a dar uma olhada em programação funcional, e tentar resumir suas manipulações em *listas* (um formato de banco de dados). Isso vai facilitar muito o seu trabalho.

- Seção 1.5:
  - Acho que sua abordagem de testar os modelos poderia ser repensada. Não está errada, porém dara para simplificar em muito e resumir isso em um punhado de modelos.
    * A minha sugestão é que você rode uma PCA em cima de todas suas covariáveis com todos os buffers testado. Essa análise já vai te selecionar um conjunto de variáveis, de todas as que você está testando. Na sequência, você faz uma análise de multicolinearidade com as variáveis que você selecionou na PCA, e seleciona apenas aquelas que não apresentaram uma correlação significativa. Essas variáveis, então, você vai considerar no seu modelo logístico, para o qual você pode adotar um método de seleção de variáveis como o *forward-stepwise approach*.
  - Dito isto, achei muito interessante ver seu nível de programação para testar os mais de 200 modelos de forma automatizada. Há formas de otimizar mais ainda o código, mas no geral está muito bom. Parabéns!

- Seção 1.6:
  - Muito boa a sua interpretação dos resultados.

Cap. 2: Dados discretos

- Seção 1.2:
  - Seu texto introdutório está muito bom e aborda os aspectos mais importantes de um dado discreto e como abordá-los no âmbito da modelagem estatística.
  - Há um ponto, contudo, que me chamou a atenção e julgo ser importante você pensar sobre isso quando voltar a analisar os seus dados:
    * Você menciona: "*Aqui modelamos a abundância de Callicebus barbarabrownae em 30 fragmentos medidos por playback*"
      · Se entendi corretamente, os dados você retira de gravações. O tempo de gravação foi padronizado? I.e., você padronizou a escuta das gravações para um tempo específico, como por exemplo, 30 min de gravação? Caso não, isso precisa ser contabilizado no seu modelo via *offset*, porque isso implica em *diferenças de esforço amostral*. Imagine que há uma maior probabilidade de detectar mais animais em um áudio mais longo do que em áudios mais curtos.
  - Preciosismo: considere corrigir sua frase *75% dos fragmentos possui abundâncias de 0 a 4 grupos por fragmento* para:
    * *75% dos fragmentos possuem até 4 grupos*
  - Mais embaixo você comenta sobre a questão do offset em relação a área do fragmento. Sua abordagem está corretíssima e fico feliz que tenha lembrado desse aspecto tão importante em dados de contagens!
    * Entretanto, reitero a questão do tempo de gravação dos áudios que você analisou para quantificar o no. de indivíduos. Se isso não foi padronizado, o seu esforço amostral (i.e., offset) deveria ser medido pelo tempo de gravação multiplicado pela área do fragmento
      · `offset(log(area x tempo))`

- Seção 2.2:

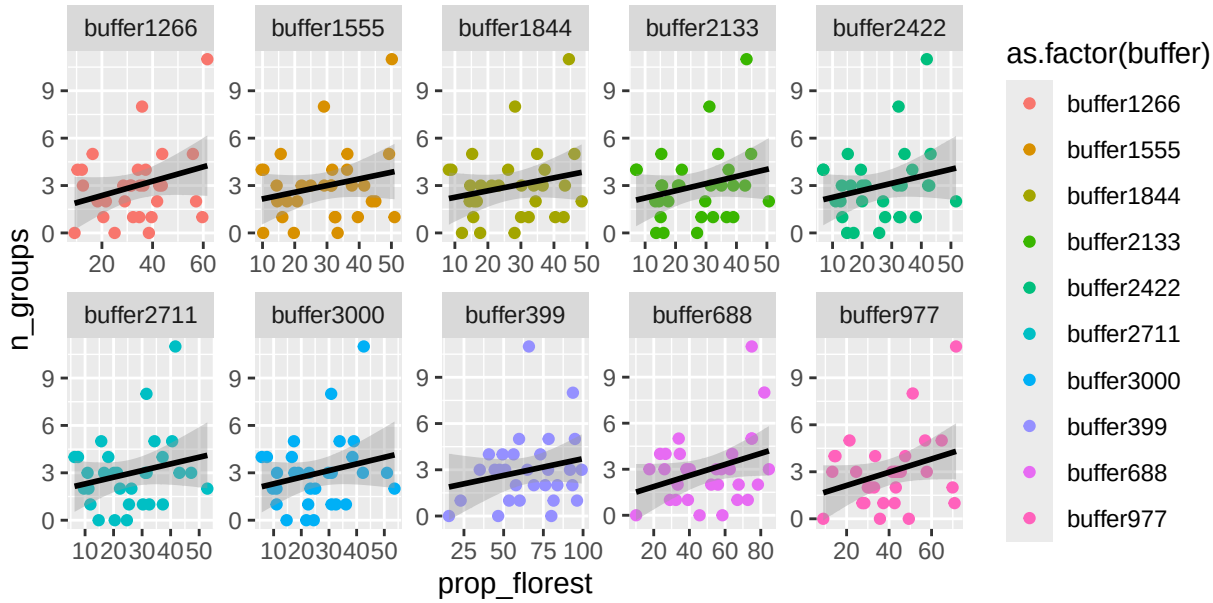
  - Considere meus comentários do primeiro capítulo aqui também em relação a sua abordagem de análise de multicolinearidade
    * I.e., rodar uma PCA para selecionar as variáveis de maior contribuição entre todas as variáveis analisadas para todos os buffers.
  - **Opa!** Faltou você fazer uma análise exploratória dos dados. Essa etapa é fundamental não apenas para detectar possíveis erros no banco de dados, como também para avaliar as relações entre sua variável resposta e covariáveis - e logo, fundamentar suas hipóteses.
    * Lembre-se que os resultados do modelo são, normalmente, um reflexo do que você vê na análise exploratória.

- Seção 2.3:
  - Se você adotar minha sugestão sobre a PCA, não precisa você fazer um modelo separadamente para cada buffer; reveja meus comentários no capítulo 1.
    * Garanto que isso vai reduzir *muito* o seu trabalho!
  - De todo modo, achei legal você ter explorado o uso de tabelas em documentos RMarkdown! Valeu pelo exercício :)
  - Vejo que na sua função `create_glm_models_objects_poisson` você padroniza as variáveis.
    * Lembre-se que isso você precisa deixar claro no texto;
    * Preciosismo: essa função poderia ser refinada um pouco mais de modo a padronizar apenas variáveis numéricas. Repare que, se por acaso,em algum momento você incluir uma variável categórica, essa função vai dar problema. Você pode incluir um `ifelse()` para verificar se a variável inserida é numérica ou não. Caso seja numérica, aí sim parte para a padronização.
  - O ajuste de todos os seus modelos está, no geral, bem ruim como você mesma observou. Posteriormente, isso precisará ser investigado com mais calma. Mas penso que minha sugestão de abordagem já pode melhorar isso.
    * Me parece que seria interessante você incluir ID do fragmento como efeito fixo no seu modelo. Assim você consegue comparar diferenças na abundância entre os diferentes fragmentos.
      · Caso o ajuste continue ruim, considere inserir ID do fragmento como efeito aleatório (no caso, você usaria um GLMM).

- Seção 2.4:
  - A interpretação dos resultados estão corretos! Lembrando que todos os coeficientes estimados encontram-se na escala log, ok?
    * Postierormente, você comenta: "*Esse é um resultado diferente do esperado, uma vez que essa espécie é altamente dependente de florestas e paisagens com maior cobertura florestal são melhores*"
      · Acredito que essa relação vá mudar quando você ajustar os modelos seguindo as minhas sugestões. Entretanto, já lhe trago a reflexão: que relação você observa quando você plota a relação de abundância vs. prop_florestal? A análise exploratória é uma etapa fundamental no processo de modelagem e deve ser feita sempre (e antes de rodar os modelos)! Já vou adiantando aqui a sua curiosidade:

```
library(ggplot2)

ggplot(dados, aes(x = prop_florest, y = n_groups, color = as.factor(buffer))) +
  geom_point() +
  geom_smooth(method = "lm", aes(group=1), colour="black") +
  facet_wrap(buffer ~ ., ncol = 5, scales = "free")
```



Cap. 3: Dados contínuos

- Seção 3.1:
  - Muito interessante a sua introdução e as hipóteses que você formulou.
    - Repare que neste capítulo você expõe de forma muito clara as suas hipóteses; não foi o caso para os demais capítulos - uma pena!
    - Repare, também, que nesta introdução você não expõe de que forma esses dados podem ser modelados (log-Normal, Gama); isso fica apenas exposto nas entrelinhas mais abaixo no capítulo.
      - **Cuidado!** Para vias de organização e clareza, é importante que você mantém o mesmo padrão entre os difrentes capítulos, ok?
- Seção 3.2:
  - Tenho algumas observações e sugestões para sua abordagem analítica:
    - 1) Não precisa (e nem faz sentido) você aplicar um modelo separado para cada ano da sua série temporal. Aqui seria o suficiente você incluir o "ano" como covariável no seu modelo - a princípio! De modo contrário, não há compartilhamento de informação entre anos, e a variação temporal é tratada como se fossem experimentos independentes. Isso obviamente não é o seu caso e sabemos que os efeitos observados em um ano dependem do ano anterior.
      - Pode ser que aqui seja necessário você considerar um modelo que inclua explícitamente a correlação temporal (AR1), ou, alternativamente, considerar um modelo que inclua o tempo como variável aleatória em um contexto de GLMM.
    - 2) Como você usa dados que remontam para 1985, fico pensando se faz sentido você extrair as variáveis ambientais no tempo atual para inferir relações num passado tão distante. Imagino que as paisagens mudaram consideravelmente de 1985 para cá, então essa mudança você não estará captando se você usar apenas variáveis que representam o tempo presente.

        - Dito isto, acho que você consegue reaver a série histórica dessas variáveis no MapBiomas. Dê uma conferida nisso se você for prosseguir com as análises deste capítulo!
    * 3) Você testa três estruturas de modelos diferentes, mas fiquei me perguntando o porquê de não ter testado um modelo com todas as três variáveis, i.e., `clumpy`, `cobertura florestal` e `densidade de fragmentos`.
    * 4) **Cuidado!** Sua abordagem de modelagem via modelo log-Normal está equivocada. Da forma que você está apresentando (i.e., transformando apenas a variável resposta no log), o modelo ainda assume a premissa de *homocedasticidade*, porque você está essencialmente usando uma distribuição 'Normal', a qual assume uma média que é independente da variância. Na distribuição log-Normal, no entanto, a média depende da variância (e vice-versa), e são expressos na escala log. Existe uma especificação matemática específica para a distribuição log-Normal. Reveja esta seção!
        - O correto teria sido você usar a distribuição `lognormal` dentro da função `glmmTMB()` - vide script da aula prática!
    * 5) **Preciosismo:** Evite fazer transformações de variáveis dentro de uma função, como faz para incluir a constante de 0.001 à variável resposta. Boas práticas de programação exigem que o programador desenvolva o script de forma clara e transparente, deixando explícitas todas as etapas do pré-processamento dos dados. Assim, quem lê o código (inclusive você mesma no futuro) compreende facilmente o que está sendo feito, em que momento e por quê. Além disso, isso facilita a reprodução e depuração da análise, caso algo precise ser revisto.
  - 6) Você comenta: "*Como esperado, de froma geral a estrura passada dos dados está melhor relacionada com a densidade atual de Callicebus barbarabrownae do que a estrutura atual.*"
    * **Cuidado!** Você não tem como fazer essa interpretação olhando apenas para os AICs. O AIC não mede a "força" da relação entre variáveis, mas sim a qualidade do ajuste do modelo, levando em conta tanto o ajuste aos dados quanto a penalização pela complexidade. Portanto, não é correto afirmar que o modelo "está melhor relacionado" à densidade com base apenas no AIC. O que se pode afirmar é que o modelo que utiliza a estrutura indicada apresentou melhor ajuste (menor AIC) entre os modelos comparados, dentro desse conjunto de hipóteses.
  - 7) Vejo que muitos dos seus modelos possuem diferenças de AICcs (delta AICc) muito marginais, indicando que tecnicamente não há diferenças significativas de um modelo para outro.
    * Aqui você poderia, por exemplo, usar um teste de razão de verossimilhança (LRT) para testar se dois modelos diferen significativamente entre eles - lembrando que só se pode aplicar o teste para modelos aninhados do mesmo banco de dados! Nesse caso, você pode, também, escolher o modelo com maior intuição biológica.
  - 8) Penso que seus modelos se ajustaram razoavelmente bem; há uma pequena violação no que diz respeito ao pressuposto de homocedasticidade, mas acredito que isso seja facilmente corrigido quando você considerar minha sugestão feita no primeiro comenário mais acima.
    * Detalhe: quando/se for reavaliar esses dados seguindo minha sugestão, é muito importante que você avalie também o pressuposto de independência temporal (e.g., via ACF plot).
- Seção 3.3:
  - Lembrando que os coeficientes estão estimados na escala da função de ligação (log)...

Cap. 4: Dados categóricos

- Seção 4.1:

  - **Preciosismo:** é importante lembrar que quando estamos no contexto multinomial, este modelo se aplica sempre quando a variável resposta possui mais de 2 categorias.
    * Quando a mesma possui apenas duas categorias (eg., sexo), retorna-se para uma modelo logístico.

- Seção 4.2:
  - Veja só! Este é o único capítulo que você explora de forma mais extensa os dados. Senti falta de você dar essa abordagem nos demais capítulos...
  - **Cuidado!** Você comenta: "*A maioria dos pinguins parece estar classificada como em sobrepeso ou abaixo do peso. Como será que isso é dentro de cada espécie?*"
    * De acordo com seu gráfico, eu interpreto que há mais pinguins saudáveis, seguidos de sobrepeso e abaixo do peso.
  - "*Irei ajustar X modelos e compará-los por AIC:*"
    * Seja mais específica. Sua frase ficou incompleta.
    * Aqui seria importante você introduzir para o leitor que método de seleção de modelos você utilizou. Vejo que você adotou o método 'forward step-wise', mas seria necessário você expor isso previamente.
      · Ademais, vejo que você incluiu a covariável `island` e `diet` no seu último modelo, mas essas variáveis não fizeram parte da sua análise exploratória. Lembre-se de manter consistência...

Seção 4.4: - No caso, a escolha entre os dois modelos se deu pelo princípio da parcimônia...o modelo mais simples que explica mais... - Sua interpretação dos resultados está parcialmente correta. - A aplicação de `exp()` aos coeficientes está correta, já que o modelo multinomial estima os efeitos na escala do log-odds, convertendo-os, assim, em razões de chance (odds ratios); perceba que isso não é a mesma interpretação de 'probabilidade'. - Atenção, contudo, à interpretação dos coeficientes. Valores de $exp(\beta) < 1$ indicam menor chance do evento em relação à categoria de referência, e não o contrário. Por exemplo, o coeficiente negativo para `speciesChinstrap` sugere menor probabilidade de sobrepeso em comparação a Adelie, e não maior. - De modo geral, as demais interpretações estão adequadas, mas é importante explicitar sempre em relação a qual categoria de referência e para qual contraste (1 ou 2) o coeficiente está sendo interpretado, ok? - Teria sido interessante você explorar esses resultados sob o ponto de vista de *probabilidade.*

Cap. 5: Distribuições complementares

- Faltou você explorar o capítulo sobre distribuições complementares.
  - Aqui poderia ter escolhido um dos três modelos apresentados em sala de aula.

Cap. 6: GAM

- Faltou você explorar o capítulo sobre GAMs.