Avaliação do relatório

- **Grupo:** Clara Buck
- **Capítulos entregues:** 4/6
- **Relatório entregue no prazo:** Não
- **Nota:** B

Comentário geral

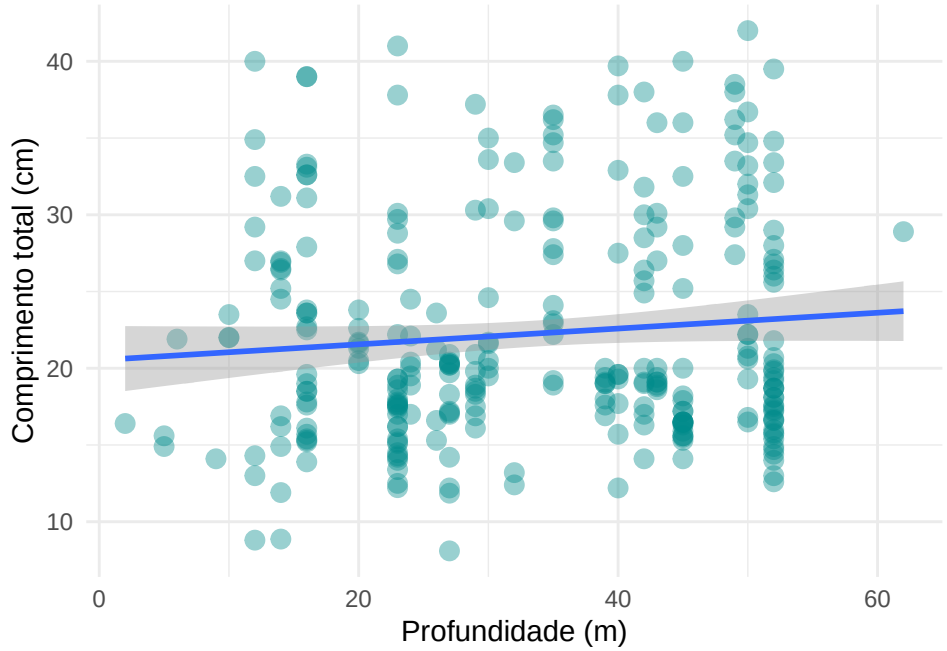
O relatório está, no geral, bem estruturado e evidencia esforço em compreender os conteúdos abordados ao longo da disciplina. No entanto, o relatório ficou bastante incompleto, com vários capítulos sem desenvolvimento adequado ou com trechos apenas parcialmente elaborados (exemplo: cap. dados binários). Em capítulos como os de dados discretos e contínuos, observa-se um início promissor de análise, mas faltam descrições textuais que contextualizem as decisões de modelagem, explicitem as hipóteses avaliadas e interpretem adequadamente os resultados - sem falar que a seção de análise exploratória ficou aquém do esperado em todos os capítulos. Destaco, ainda, que os capítulos sobre dados categóricos e GAM reproduzem quase integralmente os exemplos utilizados em aula, embora outros conjuntos de dados tenham sido indicados para o relatório. Em suma, o relatório demonstra familiaridade crescente com os métodos, mas requer maior atenção à consistência, completude e clareza na apresentação do relatório.

Comentários específicos

Cap. 1: Dados binários

- Hmh, seu capítulo sobre dados binários parece que ficou pela metade. A versão que você me enviou consta apenas até a figura na qual você avalia a relação de comprimento do peixe leão *vs.* estrato de profundidade. Veja isso, ok?
  - Não entendi o porquê de você ter categorizado sua variável `prof_m`. Podemos perder tanta informação preciosa quando categorizando uma variável. Veja como observamos um padrão muito mais claro e intuitivo quando não cateogorizamos essa variável:

```
df %>%
    filter(!is.na(ct_cm) & !is.na(prof_m)) %>%
    ggplot(aes(x = prof_m, y = ct_cm)) +
    geom_point(col = 'cyan4', size = 3 , alpha = 0.4) +
    geom_smooth(method = "lm") +
    theme_minimal() +
    labs(x = "Profundidade (m)", y = "Comprimento total (cm)")
```



Cap. 2: Dados discretos

- Seção 1:
  - Sua introdução está muito clara e objetiva. Parabéns, também, por lembrar da questão do offset - aspecto tão importante quando o esforço amostral não é constante!
- Seção 2:
  - **Opa!** Cadê a exploração dos dados? Aqui caberia você expor os gráficos exploratórios e comentar o que está observando.
- Seção 3.1:
  - Você comenta: "*O valor de dispersão foi maior que 1, indicando sobredispersão, o que torna o modelo de Poisson inadequado para esses dados.*"
    - Em momento algum você indica como chegou a essa conclusão. É importante guiar o leitor sempre...
- Seção 3.4:
  - Senti falta de você discutir mais os resultados do seu melhor modelo.
    - Em que escala estão os coeficiente estimados? Como interpretamos o sinal dos coeficientes (-/+)? Como interpretamos diante de covariáveis categóricas (fator)? O que interpretou da análise residual?...
      - Em tese, a análise residual antecede à apresentação dos resultados do modelo.
  - Como o banco de dados é espacialmente e temporalmente estruturado, é importante analisar a independência residual para esses dois componentes (`acfplot` e `bubbleplot`).
  - Você comenta: "*O modelo final indicou: efeitos significativos de temperatura da superfície do mar e profundidade;*"
    - **Cuidado!** Reveja sua interpretação, porque os resultados do `mod_5` não apontaram nenhuma covariável como estatísticamente significativa.

    - Por último, você comenta: "*... influência moderada do fator Barco,..*"
        - O que você quer dizer exatamente com isso? Não está claro como você chegou a essa conclusão olhando para os valores dos coeficientes.

- Seção 4:
  - Reveja suas conclusões. Você comenta "*A abundância de Thunnus albacares está associada a variáveis ambientais, especialmente temperatura e profundidade;*"
    - Na verdade, seus resultados mostraram o extremo oposto disso.
  - Preciosismo: Você comenta "*Modelos Poisson apresentaram sobredispersão, corrigida pelo uso da Binomial Negativa;*"
    - Não é que modelos Poisson sejam sobredispersos; são os dados que são sobredispersos. O modelo Poisson simplesmente não conseguiu corrigir essa sobredispersão. O modelo Binomial Negativo muitas vezes consegue corrigir esse problema, porque ele possui um parâmetro a mais (ϕ, parâmetro de dispersão) e que age como um fator de "correção" de sobredispersão.

Cap. 3: Dados contínuos

- Seção 1:
  - Caberia, talvez, mencionar na sua introdução quais distribuições de probabilidade são adequadas para dados contínuos (Gama e log-Normal).
    - Como você fez isso no último capítulo, isso manteria um padrão ao longo dos seus capítulos.
        - Consistência e padronização são fundamentais para garantir clareza e coesão textual. Isso não apenas facilita a leitura, como também permite que o leitor acompanhe melhor o raciocínio e a estrutura do trabalho.

- Seção 2:
  - Faltou você incluir uma seção de análise exploratória.
    - Lembre-se que essa fase é essencial dentro do processo de modelagem e temos que gastar um bom tempo nela! A análise exploratória é fundamental para detectar erros no banco de dados, bem como avaliar algumas nas nossas hipóteses. O modelo será um reflexo do que você observou na sua análise exploratória.

- Seção 3:
  - **Eita!** Sua abordagem de modelagem via modelo log-Normal está equivocada. Da forma que você está apresentando (i.e., transformando apenas a variável resposta no log), o modelo ainda assume a premissa de *homocedasticidade*, porque você está essencialmente usando uma distribuição 'Normal', a qual assume uma média que é independente da variância. Na distribuição log-Normal, no entanto, a média depende da variância (e vice-versa), e são expressos na escala log. Existe uma especificação matemática específica para a distribuição log-Normal. Reveja esta seção!
    - O correto teria sido você usar a distribuição `lognormal` dentro da função `glmmTMB()` - vide script da aula prática!
  - Por que considerou a interação `lat:long` no seu modelo?
    - Eu sei o motivo, mas outro leitor (e talvez nem você no futuro), não. Esse é o tipo de detalhe que você tem que expor em forma textual.

- Seção 4:
  - **Cuidado!** O teste de razão de verossimilhança só é válido para modelos aninhados, i.e., quando você tem um modelo mais simples que derivou de um modelo mais complexo. Você não pode usar esse teste para testar duas distribuições de probabilidade.

    - Aqui você deve/pode comparar via métricas como AIC e ajustes gráficos dos resíduos.
  - Você comenta: "*Ambos apresentaram bom ajuste, mas o modelo Gama apresentou melhor desempenho geral (menor AIC e maior logLik).*"
    - Tecnicamente, o 'bom ajuste' você consegue validar de fato quando associar esses resultados aos resultados da análise residual do(s) modelo(s).

- Seção 5:
  - Assim como no último capítulo, faltou você abordar a questão do pressuposto da independência residual, já que os dados possuem uma dimensão espacial e temporal.
    - Você comenta: "*O modelo Gama apresentou resíduos mais homogêneos e distribuição mais próxima da normalidade.*"
      - Hmh, olhando apenas para o QQ-plot, não há praticamente nenhuma distinção entre ambos os modelos. Para o gráfico de homocedasticidade, há uma indicação de uma leve violação para o modelo Gama, mas não para o log-Normal.

- Seção 6:
  - Replico aqui meu comentário já feito no último capítulo: Em que escala estão os coeficiente estimados? Como interpretamos o sinal dos coeficientes (-/+)? Como interpretamos diante de covariáveis categóricas (fator)? O que interpretou da análise residual?...
    - Você comenta sobre o efeito da interação lat/long, mas não explica como interpreta o efeito dessa relação sobre BPUE.
  - **Cuidado!** Você comenta: "*Também observou-se variação sazonal entre os meses.*"
    - Essa afirmação pode passar a ideia de que esse efeito foi significativo, quando não foi (todos os coeficientes foram não significativos). Aqui seria mais adequado você ajustar sua frase conforme: *Ainda que os resultados apontem para uma possível variação sazonal na BPUE, não há evidências estatísticas robustas que confirmem esse efeito*

- Seção 7:
  - Explique seus gráficos. Guie o leitor...

- Seção 8:
  - Reveja suas conclusões, já que a interpretação dos resultados estava equivocada.

Cap. 4: Dados categóricos

- Você replicou essencialmente o mesmo exemplo que foi apresentado na aula prática. A ideia era explorar esse capítulo conforme com o exemplo sugerido no último slide da aula 6. De modo geral, faltou bastante atenção neste capítulo. Uma pena...

- Assim como nos demais capítulos, faltou você detalhar mais as suas seções e descrever o que fez e o que observou.

- Suas conclusões gerais (seção 5) estão muito vagas e pouco informativas. Veja:
  - "*A dieta dos pinguins muda com o crescimento (massa corporal).*"
    - Como? Forneça uma informação concreta.
  - "*Diferenças claras de preferência alimentar entre espécies foram observadas.*"
    - Você não analisou isso no seu modelo - apenas na análise exploratória.
  - "*Visualizações indicam ICs confiáveis e ajudam na interpretação ecológica das preferências alimentares.*"

* De acordo com seu script, você não calculou os ICs. Para tal, você precisaria rodar as seguintes linhas de código (vide script da aula prática):

```
source("Scripts/funcoes_auxiliares.R")


preds_full <- lapply(1:n_obs, function(i) {

  eta <- preds$fit[i, ]
  se_eta <- preds$se.fit[i, ]

  probs <- softmax(eta)

  # Matriz de covariância dos preditores lineares (diagonal com variâncias)
  V_eta <- diag(se_eta^2)

  # Jacobiano da softmax
  J_soft <- softmax_jacobian(probs)

  # Método Delta: variância aproximada das probabilidades
  var_probs <- diag(J_soft %*% V_eta %*% t(J_soft))
  se_probs <- sqrt(var_probs)

  tibble(
    body_mass_g = dados_pred$body_mass_g[i],
    dieta = categorias,
    Prob = probs,
    SE = se_probs,
    IC_lower = pmax(0, probs - 1.96 * se_probs),
    IC_upper = pmin(1, probs + 1.96 * se_probs)
  )
})

preds_full <- do.call("rbind", preds_full)
```

Cap. 5: Distribuições complementares

- Faltou você explorar o capítulo sobre distribuições complementares.
  - Aqui poderia ter escolhido um dos três modelos apresentados em sala de aula.

Cap. 6: GAM

- Assim como no capítulo 4, neste capítulo você replicou integralmente o exemplo que foi apresentado na aula prática.
  - Embora eu não tenha indicado no último slide desta aula qual exemplo prático poderia ser usado para o relatório, recomendei usarem os dados da pesca para explorarem este capítulo.

  - Mesmo usando o banco de dados de bioluminescencia, julgo que poderia ter explorado outro conjunto de estações e avaliado a relação com as demais covariáveis (e.g., `Month`, `Season`, `Latitude`, `Longitude`, ...)

- Seção 3:
  - Lembrando que análise exploratória vai muito além de avaliar apenas o comportamento da variável resposta.
    * É muito (!) importante avaliar também sob a ótica da(s) sua(s) hipótese(s).
      · Neste caso, teria sido essencial apresentar o gráfico da relação entre sua variável resposta (`Sources`) e covariável (`SampleDepth`)

- Seções 4-5:
  - Entendo todo o passo-a-passo de modelagem que foi feito, mas reitero que é importante discutir essas ações e observações para o leitor.
  - Caberia você explorar bem mais os resultados que você obteve do modelo GAM
    * Por exemplo: como você interpreta o termo `edf` no efeito suavizador? E a deviance?
  - Você comenta: "*O gráfico mostra que a bioluminescência tende a aumentar até certa profundidade, seguida por uma estabilização e possível declínio em maiores profundidades.*"
    * Você precisa ser mais específica com suas observações e fornecer mais indícios para o leitor. Olhando o gráfico, eu vejo uma queda imediata de bioluminescência até +- 1000 m de profundidade, depois um ligeiro aumento até +- 1500 m e, por fim, uma queda acentuada de 1500 m em diante.